

Plateforme MLOps de Déploiement Continu de Modèles Machine Learning

1. Problématique

Dans un contexte industriel, le passage d'un modèle Machine Learning entraîné localement vers un environnement de production stable et scalable représente un défi majeur. Ce projet répond à la question suivante :


Comment automatiser et industrialiser le cycle de vie complet d'un modèle ML — de l'expérimentation au déploiement — en garantissant reproductibilité, qualité logicielle et scalabilité ?

2. Objectifs Techniques

- **Pipeline CI/CD ML** — Automatiser build, test, validation et déploiement des modèles via GitHub Actions / GitLab CI.
- **Versioning & Registry** — Gérer les versions de modèles avec MLFlow Model Registry pour assurer traçabilité et rollback.
- **Conteneurisation** — Packager chaque modèle dans une image Docker reproductible pour isolation des dépendances.
- **API d'Inférence** — Exposer les modèles via une API REST FastAPI avec endpoints de prédiction, healthcheck et métriques.
- **Monitoring Production** — Surveiller data drift, latence et performances des modèles avec alerting automatique.
- **Orchestration** — Piloter les workflows d'entraînement et de déploiement avec Kubeflow Pipelines.

3. Architecture du Système

L'architecture suit un pattern GitOps avec séparation des responsabilités entre les couches expérimentation, intégration, déploiement et monitoring.



4. Stack Technologique

Langage & Data	• Python 3.11+ • Pandas / NumPy • Scikit-learn / XGBoost • Jupyter Notebooks	MLOps & Tracking	• MLFlow (tracking + registry) • Kubeflow Pipelines • DVC (data versioning) • Weights & Biases
CI/CD & DevOps	• GitHub Actions / GitLab CI • Docker & Docker Compose • Pytest + Coverage • Pre-commit hooks	API & Serving	• FastAPI + Uvicorn • Pydantic (validation) • Swagger / OpenAPI • gRPC (optionnel)
Monitoring	• Prometheus + Grafana • Evidently AI (data drift) • ELK Stack (logs) • Alertmanager	Infrastructure	• Kubernetes (K8s) • Helm Charts • MinIO (stockage) • PostgreSQL (metadata)

5. Modules Fonctionnels

Mod.	Composant	Description technique
M1	Data Pipeline	Ingestion, validation (Great Expectations), prétraitement et versioning des datasets avec DVC.
M2	Expérimentation	Entraînement avec tracking MLFlow : hyperparamètres, métriques, artefacts, reproductibilité.
M3	Pipeline CI/CD	Tests unitaires & intégration → build image Docker → push registry → déploiement automatisé.
M4	Model Serving	API FastAPI avec endpoints /predict, /health, /metrics. Validation des inputs via schémas Pydantic.
M5	Orchestration	Kubeflow Pipelines pour orchestrer les workflows de réentraînement et déploiement continu.
M6	Monitoring	Dashboard Grafana sur métriques Prometheus. Détection data drift avec Evidently AI et alerting.

6. Planning du Projet

Phase	Intitulé	Livrables & Actions
Phase 1	Analyse & Conception	Étude de l'existant, définition de l'architecture, choix des outils, rédaction du cahier des charges technique et diagrammes UML/C4.
Phase 2	Infrastructure & CI/CD	Mise en place du dépôt Git, configuration des pipelines CI/CD, dockerisation de l'environnement, déploiement Kubernetes de base.
Phase 3	MLFlow & Expérimentation	Intégration MLFlow tracking server, configuration du Model Registry, développement des scripts d'entraînement avec logging automatique.
Phase 4	API & Intégration	Développement de l'API FastAPI, tests unitaires & d'intégration, connexion pipeline CI/CD → build image → déploiement automatique.
Phase 5	Orchestration Kubeflow	Développement des composants Kubeflow, orchestration des workflows de réentraînement, tests de bout en bout du pipeline complet.
Phase 6	Monitoring & Optimisation	Configuration Prometheus/Grafana, implémentation détection data drift, optimisation des performances, tests de charge et scalabilité.
Phase 7	Rapport & Soutenance	Rédaction du rapport technique final, préparation de la démonstration live, documentation API et guide de déploiement.

7. Valeur Ajoutée & Compétences Développées

Environnement Industriel Réel Architecture inspirée des standards MLOps en entreprise (Netflix, Spotify). Pratiques DevOps avancées appliquées au Machine Learning.	Reproductibilité Scientifique Chaque expérience est tracée, versionnée et reproductible. Conformité aux bonnes pratiques de recherche appliquée.
Scalabilité & Performance Conception orientée microservices, capable de monter en charge. Tests de performance et optimisation des temps d'inférence.	Compétences Polyvalentes Couvre ML, DevOps, Backend, Cloud et Data Engineering — profil très demandé sur le marché (stages, emplois).